Sekvence: stringovi, liste, fajlovi

Slajdovi za predmet Osnove programiranja

Katedra za informatiku, Fakultet tehničkih nauka, Novi Sad

2011.

Ciljevi

- razumevanje stringova i njihove reprezentacije u računaru
- poznavanje operacija nad stringovima
- poznavanje pojma sekvence i indeksa, primena na stringove i liste
- veština formatiranja stringova

Ciljevi 2

- poznavanje osnovnih koncepata rada sa fajlovima
- poznavanje tehnika za čitanje i pisanje fajlova u Pythonu
- razumevanje i pisanje programa koji rukuju tekstualnim fajlovima

Tip podataka string

- obrada teksta je najčešći oblik korišćenja računara
- u programima tekst je predstavljen tipom string
- string je niz (sekvenca) znakova
- navodi se unutar jednostrukih (') ili dvostrukih (") navodnika

Tip podataka string 2

```
>>> str1="Hello"
>>> str2='spam'
>>> print(str1, str2)
Hello spam
>>> type(str1)
<class 'str'>
>>> type(str2)
<class 'str'>
```

Tip podataka string 3

• unos stringa sa tastature

```
>>> firstName = input("Please enter your name: ")
Please enter your name: Žika
>>> print("Hello", firstName)
Hello Žika
```

 uneti string nije eval-uiran – želimo da memorišemo unete znakove, a ne da ih interpretiramo kao Python izraz

- možemo pristupiti pojedinačnim znakovima u stringu pomoću indeksa
- indeks predstavlja redni broj znaka u stringu
- brojanje počinje od 0
- opšti oblik je <string>[<expr>] gde vrednost expr određuje izabrani znak u stringu

```
Н
                     В
                            b
               0
           3
                  5
        2
                     6
>>> greet = "Hello Bob"
>>> greet[0]
'Н'
>>> print(greet[0], greet[2], greet[4])
H 1 o
>>> x = 8
>>> print(greet[x - 2])
В
```

Н	е		ı	0		В	0	b
0	1	2	3	4	5	6	7	8

- u stringu od n znakova, poslednji znak je na poziciji n-1 jer brojanje počinjemo od 0
- možemo brojati i sa desnog kraja pomoću negativnih brojeva

```
>>> greet[-1]
'b'
>>> greet[-3]
'B'
```

- indeksiranje vraća string koji sadrži tačno jedan znak
- možemo izdvojiti i duži podniz znakova iz stringa podstring (substring)
- postupak isecanja (slicing)

- start i end moraju biti tipa int
- isečak (slice) sadrži podstring od start-nog znaka (uključivo) do end-nog (isključivo)

```
H e I I o B o b
0 1 2 3 4 5 6 7 8
```

```
>>> greet[0:3]
'Hel'
>>> greet[5:9]
' Bob'
>>> greet[:5]
'Hello'
>>> greet[5:]
' Bob'
>>> greet[:]
'Hello Bob'
```

 ako nedostaju start ili end podrazumevaju se početak odnosno kraj stringa

Konkatenacija i ponavljanje stringa

- konkatenacija predstavlja "spajanje" stringova kraj prvog stringa sa početkom drugog
- operator za konkatenaciju je +
- ponavljanje predstavlja višestruku konkatenaciju stringa sa samim sobom
- operator za ponavljanje je *

Konkatenacija i ponavljanje stringa 2

```
>>> "spam" + "eggs"
'spameggs'
>>> "Spam" + "And" + "Eggs"
'SpamAndEggs'
>>> 3 * "spam"
'spamspamspam'
>>> "spam" * 5
'spamspamspamspamspam'
>>> (3 * "spam") + ("eggs" * 5)
'spamspamspamspameggseggseggseggseggs'
```

Dužina stringa

• funkcija len vraća dužinu (broj znakova) stringa

Operacije nad stringom

operator	značenje		
+	konkatenacija		
*	ponavljanje		
<string>[]</string>	ponavljanje indeksiranje		
<string>[:]</string>	isecanje		
for <var> in <string></string></var>	iteracija kroz znakove		

Primeri obrade stringova

 korisničko ime u nekom računarskom sistemu: prvo slovo imena i prvih 7 slova prezimena

```
first = input("Unesite ime: ")
last = input("Unesite prezime: ")
username = first[0] + last[:7]
```

Formiranje korisničkog imena

```
Unesite ime: ana
Unesite prezime: tot
username = atot
```

Unesite ime: dimitrije Unesite prezime: dimitrijević

username = ddimitri

- smestimo sve troslovne oznake u jedan veliki string:
 "JanFebMarAprMajJunJulAvgSepOktNovDec"
- koristimo redni broj meseca kao indeks za string: mesecSkr = meseci[pos:pos+3]
- da bismo izračunali pos, treba od broja meseca oduzeti 1 i pomnožiti to sa 3

mesec	broj	pos
Jan	1	0
Feb	2	3
Mar	3	6
Apr	4	9

```
# month.py
  Štampa skraćeno ime meseca za dati redni broj
# ovde čuvamo nazive
meseci = "JanFebMarAprMajJunJulAvgSepOktNovDec"
n = eval(input("Unesite mesec (1-12): "))
# izračunaj indeks u stringu
pos = (n-1) * 3
# iseci podstring
mesecSkr = meseci[pos:pos+3]
# ispiši rezultat
print ("Skraćenica je", mesecSkr + ".")
```

```
$ python month.py
Unesite mesec (1-12): 1
Skraćenica je Jan.
$ python month.py
Unesite mesec (1-12): 12
Skraćenica je Dec.
```

- ovo rešenje je ispravno samo ako su nazivi svih meseci iste dužine
- kako da to prevaziđemo?

Stringovi, liste, sekvence

- string je specijalni oblik sekvence
- string operacije postoje za sve sekvence!

```
>>> [1,2] + [3,4]
[1, 2, 3, 4]
>>> [1,2]*3
[1, 2, 1, 2, 1, 2]
>>> grades = ['A', 'B', 'C', 'D', 'F']
>>> grades[0]
, Α,
>>> grades[2:4]
['C', 'D']
>>> len(grades)
5
```

Stringovi, liste, sekvence 2

- string je uvek sekvenca znakova
- lista može da sadrži bilo kakve podatke brojeve, stringove, ili oba

```
myList = [1, "Spam ", 4, "U"]
```

- string je uvek sekvenca znakova
- lista može da sadrži bilo kakve podatke brojeve, stringove, ili oba

```
meseci = ["Jan", "Feb", "Mar", "Apr", "Maj", "Jun", "Jul", "Avg", "Sep", "Okt", "Nov", "Dec"]
```

- naredba dodele vrednosti se proteže preko dva reda
- Python zna da nije završena u prvom redu pa dalje čita tekst programa

• sada se naziv meseca dobija ovako:

```
mesecSkr = meseci[n-1]
```

umesto ovako:

```
mesecSkr = meseci[pos:pos+3]
```

 pošto je indeks lako izračunati, nije nam neophodna pomoćna promenljiva

Redni broj meseca u godini → naziv meseca

• ova verzija programa se lako menja za rad sa punim nazivima

```
meseci = ["Januar", "Februar", "Mart", "April", "Maj", "Jun",
    "Jul", "Avgust", "Septembar", "Oktobar", "Novembar",
    "Decembar"]
```

Menjanje sekvence, stringa i liste

- sekvenca je lista koja se ne može menjati
- string je sekvenca ⇒ ne može se menjati
- lista se može menjati

```
>>> myList = [34, 26, 15, 10]
>>> myList[2]
15
>>> mvList[2] = 0
>>> myList
[34, 26, 0, 10]
>>> myString = "Hello World"
>>> myString[2]
,,,
>>> myString[2] = "p"
Traceback (most recent call last):
  File "<pyshell#16>", line 1, in -toplevel-
    mvString[2] = "p"
TypeError: object doesn't support item assignment
```

Kodni rasporedi

- kodni raspored: mapiranje slova na brojeve radi reprezentacije slova u memoriji
- u davna vremena, svaki proizvođač računara je imao sopstveni kodni raspored
- ASCII standard: 7-bitni kodni raspored (127 slova)
- Unicode standard: preko 100.000 različitih slova
- Python radi sa Unicode slovima (default od verzije 3)

Konverzija slovo ↔ broj

- funkcija ord vraća numerički kod za dato slovo
- funkcija chr vraća slovo za dati numerički kod

```
>>> ord("A")
65
>>> ord("a")
97
>>> chr(97)
'a'
>>> chr(65)
'A'
```

Primer: konverzija string ↔ niz brojeva

- algoritam je jednostavan:
- 1 unesi string za konverziju
- 2 za svaki znak u stringu:
- 2a ispiši numerički kod znaka
 - for petlja ide kroz sekvencu, a string je sekvenca: for <ch> in <string>:

Primer: konverzija string ↔ niz brojeva 2

```
# text2numbers.py
#
      Konvertuje string u niz brojeva koristeći Unicode
#
      kodni raspored
print("Konvertuje string u niz brojeva koristeći")
print("Unicode kodni raspored.\n")
# unesi tekst
message = input("Unesite tekst za kodiranje: ")
print("\nOvo su Unicode kodovi:")
# za svaki znak u stringu ispiši njegov kod
for ch in message:
   print(ord(ch), end=" ")
print()
```

Primer: konverzija niz brojeva ↔ string

- bilo bi lepo imati i program koji radi inverziju prethodnog
- algoritam za dekoder bi mogao da glasi:
- 1 unesi niz brojeva za dekodiranje
- 2 message ← ""
- 3 za svaki broj u nizu:
- 3a konvertuj broj u znak
- 3b dodaj znak na kraj message
 - 4 ispiši message

Primer: konverzija niz brojeva ↔ string 2

- promenljiva message je akumulator
- inicijalno postavljena na prazan string
- u svakom prolazu petlje jedan broj se konvertuje u znak
- i dodaje na kraj akumulatora

Primer: konverzija niz brojeva ↔ string 2

- kako da unesemo sa tastature niz brojeva promenljive dužine?
- učitamo ga kao string, pa podelimo na delove koji predstavljaju pojedinačne brojeve
- novi algoritam:
- 1 unesi niz brojeva kao string
- 2 message ← ""
- 3 za svaki od podstringova:
- 3a konvertuj niz znakova koji predstavljaju broj u broj
- 3b konvertuj taj broj u znak
- 3c dodaj znak na kraj message
 - 4 ispiši message

Funkcija split

podeli string na podstringove, u odnosu na neki separator-znak

```
>>> "Hello string methods!".split()
['Hello', 'string', 'methods!']
>>> "32,24,25,57".split(",")
['32', '24', '25', '57']
>>>
```

Funkcija eval

ullet konverzija string o broj pomoću funkcije eval

```
>>> numStr = "500"
>>> eval(numStr)
500
>>> x = eval(input("Enter a number "))
Enter a number 3.14
>>> print x
3.14
>>> type (x)
<type 'float'>
```

Primer: konverzija niz brojeva ↔ string 2

```
# numbers2text.py
#
      Konvertuje niz Unicode brojeva u string
print("Konvertuje niz Unicode brojeva u string.\n")
# unesi poruku
inString = input("Unesite poruku kao Unicode niz: ")
# za svaki podstring odredi znak i dodaj ga u rezultat
message = ""
for numStr in inString.split(" "):
    # konvertuj podstring u broj
    codeNum = eval(numStr)
    # dodaj znak na kraj rezultata
   message = message + chr(codeNum)
print("\nDekodirana poruka je:", message)
```

Primer: konverzija niz brojeva ↔ string 2

\$ python text2numbers.py Konvertuje string u niz brojeva koristeći Unicode kodni raspored.

Unesite tekst za kodiranje: Pajton je zakon

Ovo su Unicode kodovi: 80 97 106 116 111 110 32 106 101 32 122 97 107 111 110

\$ python numbers2text.py
Konvertuje niz Unicode brojeva u string.

Unesite poruku kao Unicode niz: 80 97 106 116 111 110 32 106 101 3

Dekodirana poruka je: Pajton je zakon

Još funkcija za stringove

- postoji puno funkcija koje operišu nad stringovima
- s.capitalize() kopija s sa prvim znakom pretvorenim u veliko slovo
- s.title() kopija s sa prvim znakom svake reči pretvorenim u veliko slovo
- s.center(width) centriraj s u string dužine width
- s.ljust(width) kao center, samo je tekst poravnat sa leve strane
- s.rjust(width) kao center, samo je tekst poravnat sa desne strane

Još funkcija za stringove 2

- s.count(sub) broj pojavljivanja podstringa sub u stringu s
- s.find(sub) indeks prvog mesta gde se podstring sub pojavljuje u stringu s
- s.rfind(sub) kao find, samo traži podstring sa desne strane
- s.join(list) konkatenraj stringove iz liste list koristeći s kao separator

Još funkcija za stringove 3

- s.lower() konvertuje sve u mala slova
- s.upper() konvertuje sve u velika slova
- s.1strip() ukloni razmake (whitespace) sa početka stringa
- s.rstrip() ukloni razmake (whitespace) sa kraja stringa
- s.split(sep) podeli s na delove oko znakova sep
- s.replace(oldsub, newsub) zameni sve podstringove oldsub u stringu s sa newsub

- često moramo da "ulepšamo" string pre ispisa
- recimo da ho
 ćemo da konvertujemo datum iz oblika "15.10.2011." u oblik "15. oktobar 2011."
- 1 unesi datum u formatu dd.mm.gggg.
- 2 podeli string oko tačke u dan, mesec i godinu
- 3 konvertuj broj meseca u naziv
- 4 formiraj novi string u obliku dd. mesec gggg.
- 5 ispiši novi string

- prva dva reda su jednostavna: dateStr = input('Unesite datum (dd.mm.gggg.): ') dayStr, monthStr, yearStr, x = dateStr.split('.')
- datum se učita kao string, pa se podeli oko tačke na 4 dela
- prva tri dela upišemo u bitne promenljive

- sledeći korak: konvertovati monthStr u broj
- možemo da koristimo funkciju int int("05") = 5

 eval neće raditi za brojeve sa vodećim nulama (vodeća nula je nekad označavala oktalni broj)

```
months = ["januar", "februar", ..., "decembar"]
monthStr = months[int(monthStr) - 1]
```

- indeks u listi počinje od nula, zato oduzimamo 1 od broja meseca
- ostaje još konkatenacija rezultujućeg stringa

```
print ("Konvertovani datum je:", dayStr+".",
    monthStr, yearStr+".")
```

• tačka je dodata na dayStr i yearStr konkatenacijom

```
Unesite datum (dd.mmm.gggg.): 15.10.2011.
Konvertovani datum je: 15. oktobar 2011.
```

$\mathsf{Broj} \to \mathsf{string}$

za konverziju broj → string možemo da koristimo funkciju str

```
>>> str(500)
'500'
>>> value = 3.14
>>> str(value)
'3.14'
>>> print("The value is", str(value) + ".")
The value is 3.14.
```

Broj → string i konkatenacija

- ako je neka vrednost string, možemo konkatenirati tačku na njen kraj
- ako je ta vrednost int, šta onda?

```
>>> value = 3.14
>>> print("The value is", value + ".")
The value is

Traceback (most recent call last):
   File "<pyshell#10>", line 1, in -toplevel-
        print "The value is", value + "."

TypeError: unsupported operand type(s) for +: 'float' and 'str'
```

Operacije za konverziju

funkcija	značenje
float(expr)	konvertuj expr u float vrednost
<pre>int(expr)</pre>	konvertuj expr u int vrednost
str(expr)	vrati string reprezentaciju od expr
eval(str)	izračunaj str kao Python izraz

Change Counter

Please enter the count of each coin type.

Quarters: 6 Dimes: 0

Nickels: 0
Pennies: 0

The total value of your change is 1.5

• bilo bi lepše da na kraju piše \$1.50

• možemo da preradimo ispis rezultata ovako:

```
print("Your change is ${0:0.2f}".format(total))
```

sada ćemo dobiti nešto ovako:

The total value of your change is \$1.50

- <šablon>.format(<vrednosti>)
- vitičaste zagrade {...} označavaju mesta u koja se upisuju vrednosti
- svako mesto ima format

```
print("Your change is ${0:0.2f}".format(total))
```

- šablon sadrži jedno mesto sa opisom 0:0.2f
- opis ima format <index>:<format-spec>
- index je redni broj parametra koga treba upisati
- format-spec ima oblik: <width>.<precision><type>
- width je broj znakova koju vrednost treba da zauzima;
 0 znači da zauzme koliko je potrebno
- precision je broj decimala
- f znači broj u "fiksnom zarezu"

```
>>> "Hello {0} {1}, you may have won ${2}" .format("Mr.", "Smith", 10000)
'Hello Mr. Smith, you may have won $10000'
>>> 'This int, {0:5}, was placed in a field of width 5'.format(7)
'This int, 7, was placed in a field of width 5'
>>> 'This int, {0:10}, was placed in a field of witdh 10'.format(10)
'This int.
               10, was placed in a field of witdh 10'
>>> 'This float, {0:10.5}, has width 10 and precision 5.'.format(3.1415926)
'This float, 3.1416, has width 10 and precision 5.'
>>> 'This float, {0:10.5f}, is fixed at 5 decimal places.'.format(3.1415926)
'This float, 3.14159, has width 0 and precision 5.'
```

- ako je width veči nego što je potrebno
 - podrazumevano poravnanje:
 - numerički podaci se poravnavaju po desnoj strani
 - stringovi se poravnavaju po levoj strani
- poravnanje se može eksplicitno navesti pre width

```
>>> "left justification: {0:<5}.format("Hi!")
'left justification: Hi! '
>>> "right justification: {0:>5}.format("Hi!")
'right justification: Hi!'
>>> "centered: {0:^5}".format("Hi!")
'centered: Hi!'
```

Novčani iznosi

- brojevi u pokretnom zarezu su nezgodni za čuvanje novčanih iznosa
- možemo čuvati novac u parama/centima kao int i konvertovati u dinare/evre i pare/cente prilikom ispisa
- ako je total vrednost u evro centima:

```
euros = total // 100
cents = total % 100
```

- centi se ispisuju sa širinom 0>2 da bismo dobili desno poravnat broj sa vodećim nulama
- tako se 5 centi ispisuje kao 05

Novčani iznosi 2

```
# change2.py
print ("Change Counter\n")
print ("Please enter the count of each coin type.")
quarters = eval(input("Quarters: "))
dimes = eval(input("Dimes: "))
nickels = eval(input("Nickels: "))
pennies = eval(input("Pennies: "))
total = quarters * 25 + dimes * 10 + nickels * 5 + pennies
print ("The total value of your change is ${0}.{1:0>2}"
    .format(total//100, total%100))
```

Novčani iznosi 3

Change Counter

Please enter the count of

each coin type.

Quarters: 0

Dimes: 0 Nickels: 0

Pennies: 1

The total value of your change is \$0.01

Change Counter

Please enter the count of

each coin type.

Quarters: 12

Dimes: 1 Nickels: 0

Pennies: 4

The total value of your change

is \$3.14

Fajlovi

- fajl (datoteka) je sekvenca podataka koji se čuva na sekundarnoj memoriji (disku)
- fajlovi mogu da sadrže bilo koji tip podataka
- najlakše je raditi sa tekstom
- tekstualni fajl tipično sadrži više redova teksta
- Python koristi line feed znak (\n, str(10)) da označi kraj reda

Višelinijski stringovi

Hello World

Goodbye 32

• kada se ovaj string snimi u fajl, on izgleda ovako:

Hello\nWorld\n\nGoodbye 32\n

Višelinijski stringovi

- ovo radi na isti način kao ugrađivanje \n u print naredbe
- ovi znakovi utiču samo na ispis; ne utiču na izračunavanje izraza

Obrađivanje fajlova

- proces otvaranja fajla uključuje povezivanje fajla na disku sa objektom u memoriji
- nakon otvaranja možemo menjati fajl putem tog objekta
 - čitanje iz fajla
 - pisanje u fajl
- nakon obavljenog posla, fajl je potrebno zatvoriti

Zatvaranje fajla

- zatvaranje fajla će pokrenuti sve operacije nad fajlom koje do tada nisu izvršene
 - snimanje podataka
 - pražnjenje bafera, itd.
- ako zaboravimo da zatvorimo fajl, moguće je da će doći do gubitka nekih podataka!

Čitanje fajla

- učitavanje fajla u tekst-editor
 - otvaranje fajla
 - učitavanje sadržaja fajla u memoriju
 - zatvaranje fajla
 - izmene nad sadržajem se obavljaju u memoriji, fajl se ne menja!

Snimanje fajla

- snimanje fajla iz memorije na disk
 - originalni fajl je otvara u režimu koji omogućuje upis podataka
 to će obrisati stari sadržaj!
 - operacije za upis podataka će iskopirati sadržaj iz memorije na disk
 - zatvaranje fajla (obavezno!)

Tekstualni fajlovi i Python

otvaranje fajla (kreiranje objekta u memoriji koji predstavlja fajl)

```
<filevar> = open(<name>, <mode>)
```

- name je string koji predstavlja ime fajla na disku
- mode je "r" ili "w" zavisno od toga da li čitamo ili pišemo u fajl

```
infile = open("numbers.dat", "r")
outfile = open("numbers2.dat", "w")
```

Operacije nad fajlom

- <file>.readline() vraća narednu liniju teksta iz fajla uključujući i \n
- <file>.readlines() vraća listu preostalih linija teksta iz fajla; elementi liste su redovi teksta koji se završavaju sa \n

Primer operacija nad fajlom

```
# printfile.py

fname = input("Enter filename: ")
infile = open(fname,'r')
data = infile.read()
print(data)
infile.close()
```

- 1 korisnik unosi ime fajla
- 2 fajl se otvara za čitanje
- 3 ceo fajl se učitava i smešta u string data
- 4 string data se ispisuje

Čitanje celog fajla

 readline se može upotrebiti za čitanje sledećeg reda iz fajla, uključujući i \n

```
infile = open(someFile, "r")
for i in range(5):
    line = infile.readline()
    print(line[:-1])
infile.close()
```

- čita prvih 5 redova iz fajla
- uklanjanje \n se obavlja pomoću split

Čitanje celog fajla 2

- drugi način je da pročitamo sve redove pomoću readlines
- i da u petlji prođemo kroz listu stringova

```
infile = open(someFile, "r")
for line in infile.readlines():
     # uradi nešto sa tekućim redom
infile.close()
```

Čitanje celog fajla ₃,

Python tretira fajl-objekat kao sekvencu redova!

```
infile = open(someFile, "r")
for line in infile:
    # uradi nešto sa tekućim redom
infile.close()
```

Pisanje u fajl

- otvaranje fajla za upis priprema fajl za prijem podataka
- ako se otvori postojeći fajl, njegov sadržaj će biti obrisan
- ako fajl prethodno ne postoji, biće kreiran novi fajl

```
outfile = open(someFile, "w")
print(sadržaj, file=outfile)
```

Batch režim rada

- batch režim rada: nema neposrednog unosa/ispisa podataka
- ulaz i izlaz se odvija preko fajlova
- primer: kreiranje korisničkih imena (username) na osnovu imena i prezimena

Batch režim rada 2

```
infileName = input("Input file? ")
outfileName = input("Output file? ")
infile = open(infileName, 'r')
outfile = open(outfileName, 'w')
for line in infile:
    first, last = line.split()
    uname = (first[0]+last[:7]).lower()
    print(uname, file=outfile)
infile.close()
outfile.close()
print("Written to", outfileName)
```

Batch režim rada 3

- programi često imaju otvoreno više fajlova
- funkcija lower je zgodna za konverziju imena fajlova u mala slova